Agentes tabulares de aprendizaje por refuerzo para invertir en un activo: Q-learning y Sarsa

Aprendizaje por Refuerzo, MIAX-14 · Taller trader · Grupo: Alonso, Piettro y Raúl · Código y resultados: github.com/raulrodriguezlr/B5-Reinforcement-learning

1. Planteamiento y decisiones de diseño

- **Entorno.** Se usa `SimpleTradingEnv` del enunciado sin cambios: acciones vender, mantener y comprar; recompensa igual al retorno del paso si se tiene el activo, menos 0,1 % por operación; capital inicial 1000. Cada episodio recorre 494 pasos de una serie de 500 precios.
- **Estado discreto.** La tendencia observada es continua y, medida sobre series reales de cada generador, vive en torno a ±0,06 (±0,35 en tendencia + ciclo): el recorte a ±1 del entorno nunca actúa y diez tramos uniformes en [−1, 1] dejarían casi todos los estados en un único tramo. Por eso se discretiza en **10 tramos por cuantiles**, ajustados para cada generador con 200 series propias (nunca de test). El estado es (tramo, posición) y la tabla Q tiene forma 10×2×3.
- **Entrenamiento.** Cada episodio usa una **serie nueva** del mismo generador (3000 episodios). Política ε-greedy con ε decreciente de 1 a 0,05 y α decreciente (×0,998 por episodio, mínimo 0,01): con α constante la política greedy seguía cambiando en casi todos los episodios por valores Q casi empatados.
- **Datos y ajuste.** Semillas disjuntas para entrenamiento, validación (50 series) y test (100 series). Hiperparámetros elegidos solo en validación (mediana del log-retorno de la política greedy) con la rejilla α ∈ {0,05; 0,2}, γ ∈ {0; 0,9; 0,99}, decaimiento de ε ∈ {0,995; 0,999} y 3 semillas. Gana γ = 0,9 en tendencia + ciclo y γ = 0,99 en reversión; en browniano y regímenes casi todo empata en "no operar".
- **Evaluación.** 5 semillas por algoritmo; política greedy final sobre las mismas 100 series de test que los baselines (aleatorio, buy & hold). Medianas por serie, porque el generador 1 da balances muy asimétricos. Convergencia: primer episodio desde el que el rendimiento en validación queda en tolerancia del valor final durante al menos 200 episodios.

2. Resultados en test

Generador	Método	Balance (mediana)	Log-ret. medio ± std runs	Exceso vs B&H (pp)	Sharpe	Drawdown (%)	Operac.	% en mercado	Conv. val (episodio)
Tendencia + ciclo	**Q-learning**	**473 712**	**6,30 ± 0,21**	**33 331**	**0,188**	**65,4**	**47**	**65,1**	**n/c (0/5)**
	Sarsa	**463 976**	**6,30 ± 0,38**	**33 757**	**0,188**	**66,1**	**50**	**64,4**	**2549 (1/5)**
	Buy & hold	33 458	3,61	0	0,120	89,2	1	100,0	n/c
	Aleatorio	4 568	1,60	−2 613	0,078	78,3	166	49,0	n/c
Browniano	**Q-learning**	**1 000**	**−0,02 ± 0,04**	**−0,3**	**0,000**	**0,0**	**0**	**0,0**	**2099 (2/5)**
	Sarsa	**1 000**	**−0,03 ± 0,06**	**−0,3**	**0,000**	**0,0**	**0**	**0,0**	**2232 (3/5)**
	Buy & hold	989	−0,01	0	0,009	37,7	1	100,0	n/c
	Aleatorio	809	−0,17	−15,9	−0,024	32,2	166	49,0	n/c
Reversión a la media	**Q-learning**	**1 215**	**0,18 ± 0,02**	**21,7**	**0,038**	**18,2**	**63**	**34,8**	**2749 (1/5)**
	Sarsa	**1 203**	**0,17 ± 0,02**	**19,9**	**0,041**	**14,9**	**44**	**20,6**	**2049 (1/5)**
	Buy & hold	994	−0,00	0	0,010	25,5	1	100,0	n/c
	Aleatorio	872	−0,14	−13,9	−0,013	30,8	166	49,0	n/c
Regímenes	**Q-learning**	**1 000**	**0,03 ± 0,03**	**17,2**	**0,000**	**12,9**	**33**	**30,5**	**n/c (0/5)**
	Sarsa	**1 000**	**0,00 ± 0,00**	**12,6**	**0,000**	**0,0**	**0**	**0,0**	**2019 (5/5)**
	Buy & hold	874	−0,16	0	−0,007	43,4	1	100,0	n/c
	Aleatorio	767	−0,26	−8,7	−0,033	35,1	166	49,0	n/c

Tabla 1. 100 series de test por generador (agentes: 5 semillas). Salvo el log-retorno (media ± desviación entre semillas), todo son medianas por serie. Conv. val: episodio medio de las semillas que convergen (convergidas/total); n/c, sin convergencia en 3000 episodios. Entrenar 3000 episodios cuesta 28 a 36 s en ambos algoritmos.

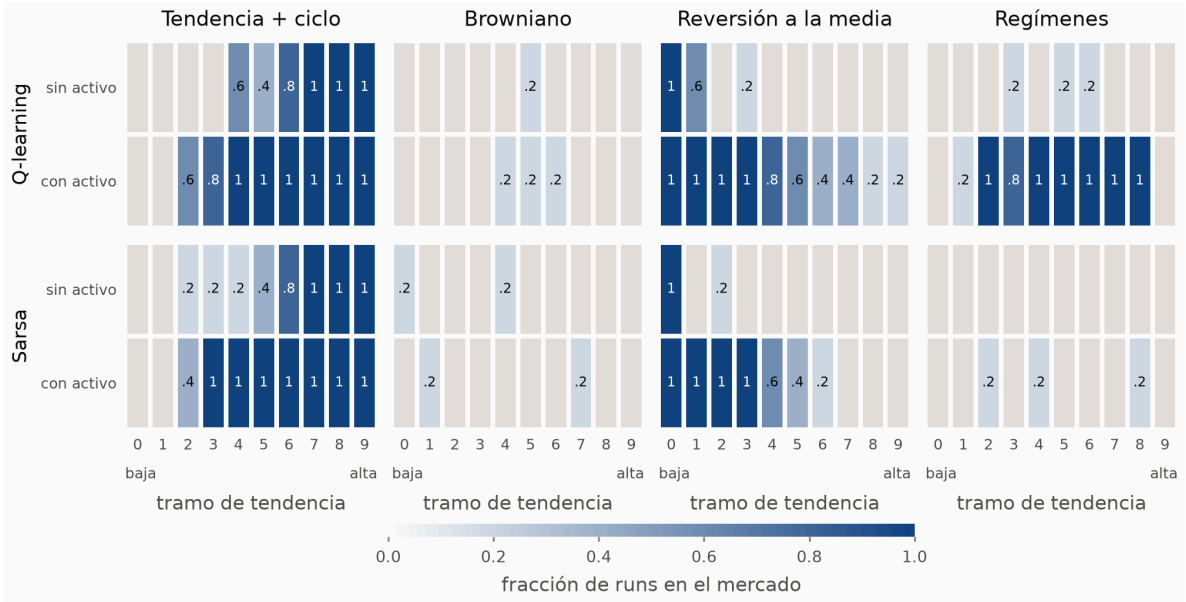


Figura 1. Política greedy final: fracción de las 5 semillas cuya acción deja la cartera dentro del mercado, por tramo de tendencia (0 la más baja) y posición actual. Gris: ninguna semilla entra.

3. Análisis por generador: ¿es la estrategia esperada?

- **Tendencia + ciclo: seguimiento de tendencia, esperado.** El agente entra con tendencia alta y sale con tendencia negativa (figuras 1 y 3). Multiplica el log-retorno de buy & hold (6,3 frente a 3,6) con menos drawdown (65 % frente a 89 %). El resultado es tan bueno porque el ciclo del generador es determinista: `sin(t)` sobre la misma rejilla de tiempo tiene la misma fase en todas las series (periodo de unos 63 pasos), y la tendencia de 6 pasos revela en qué tramo del ciclo se está. Es un patrón aprendible en este simulador, no una propiedad de un mercado real.
- **Browniano: no operar, esperado.** Con incrementos independientes la tendencia no contiene información sobre el retorno siguiente, así que ninguna política puede batir en esperanza a buy & hold, y la comisión hace que operar sea negativo. Ambos agentes aprenden a quedarse en efectivo: igualan a buy & hold en mediana (−0,3 pp) con drawdown nulo. Responde a la pregunta abierta de clase: con precios aleatorios lo óptimo es "da igual" y, con costes, no operar.
- **Reversión a la media: estrategia contraria, esperada.** Compra solo en el tramo de tendencia más negativo y mantiene hasta que la tendencia se vuelve positiva. La asimetría entre entrar (solo en el tramo 0) y salir (desde el tramo 4) es una banda de histéresis que ahorra comisiones. Supera a buy & hold en unos 20 pp. Sarsa es más selectivo (21 % del tiempo en mercado frente a 35 %) con menor drawdown.

- **Regímenes: seguimiento de tendencia solo parcial.** Lo esperado es estar dentro en régimen alcista y fuera en bajista. Q-learning entra rara vez pero, una vez dentro, mantiene salvo tendencia extrema; Sarsa no opera nunca. Ambos superan a buy & hold (que pierde un 16 % en mediana porque el régimen bajista tiene más caída y volatilidad), pero sobre todo por evitar el mercado: una ventana de 6 pasos distingue mal el régimen oculto en un ruido del 1 al 2,5 % por paso.

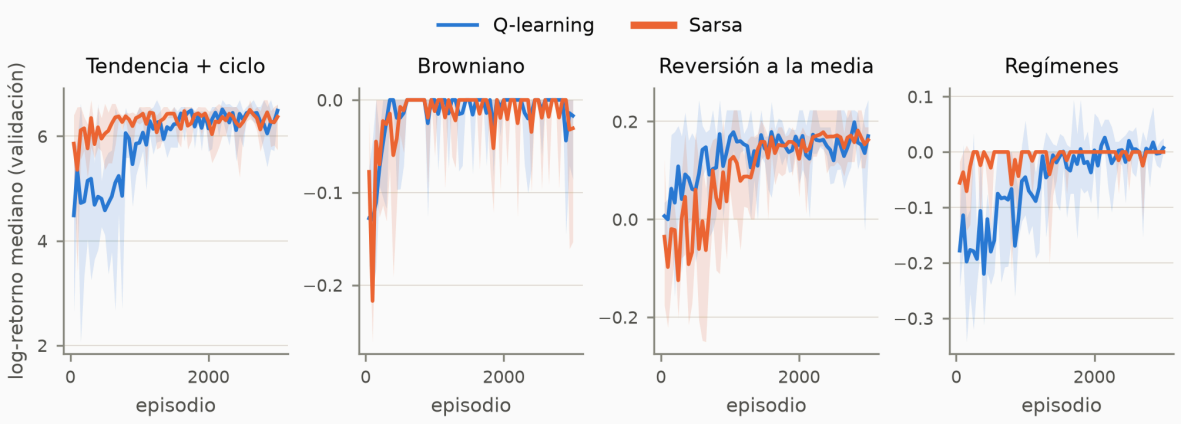


Figura 2. Mediana del log-retorno en validación de la política greedy cada 50 episodios: media de 5 semillas y banda entre mínimo y máximo.

4. Q-learning frente a Sarsa y convergencia

El rendimiento final es similar en los cuatro generadores y el coste por episodio también (unos 10 ms). La diferencia está en el estilo: **Sarsa es más conservador** (menos tiempo en mercado en reversión y ninguna operación en regímenes), como predice la teoría: al ser *on-policy* evalúa la política ε-greedy que incluye exploración, igual que en el ejemplo del acantilado, mientras que Q-learning evalúa la greedy. En tendencia + ciclo Sarsa alcanza la meseta en validación en unos 300 episodios y Q-learning hacia el 1000 (figura 2). Los criterios estrictos de convergencia rara vez se cumplen en 3000 episodios (columna Conv. val): el rendimiento se estabiliza, pero la política oscila en celdas con valores Q casi empatados, que son justo los estados sin ventaja explotable. $\gamma > 0$ gana donde hay estructura, porque valora mantener la posición frente a pagar comisión en cada cambio; $\gamma = 0$ nunca es mejor salvo en empates.

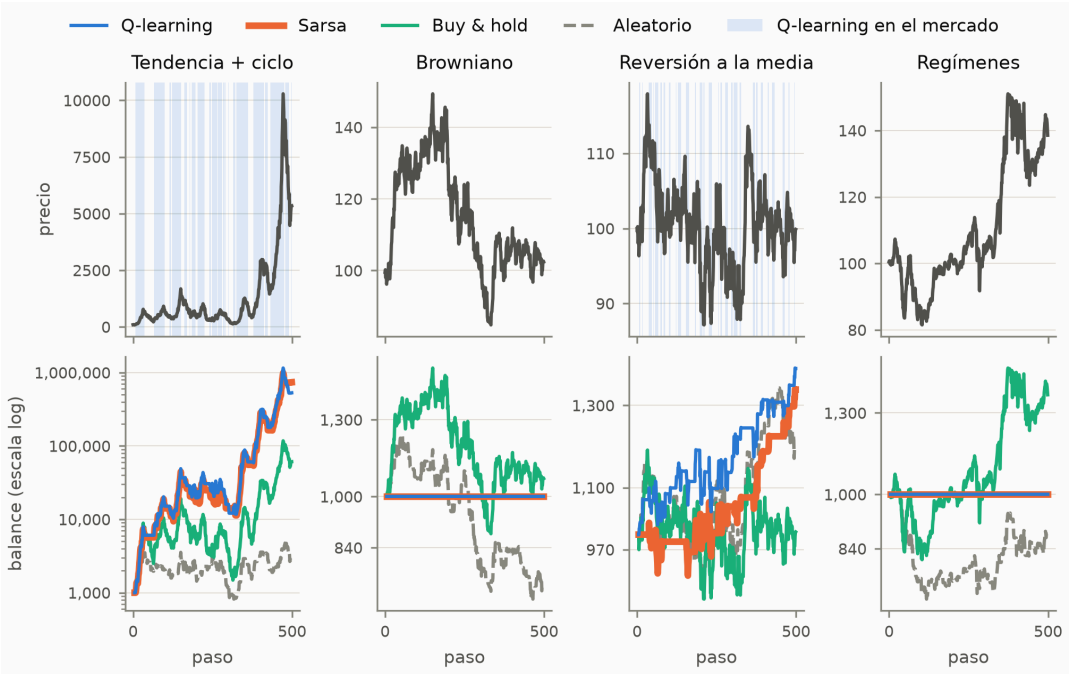


Figura 3. Una serie de test por generador. Arriba, precio con sombreado donde Q-learning tiene el activo; abajo, balance en escala logarítmica de cada método (Q-learning y Sarsa coinciden en 1000 cuando no operan).

5. Análisis crítico y limitaciones

- El estado (tendencia de 6 pasos, posición) no es markoviano: en regímenes el régimen está oculto y en reversión no se observa la distancia al nivel de equilibrio. Ampliar el estado (por ejemplo, desviación respecto a una media larga) es la mejora más directa.
- El generador 1 premia un ciclo de fase fija; en series reales ese patrón no existe, y los resultados no son trasladables a mercado (además habría sesgo de supervivencia y costes distintos).
- El ajuste usa una sola medición final en validación y 3 semillas: es ruidoso, y en browniano y regímenes la rejilla no discrimina. Con 3000 episodios varias semillas no llegan a estabilizarse.
- Pendiente como extensión: entrenar mezclando generadores, sensibilidad al número de tramos, Monte Carlo on-policy y una serie real como comprobación.

6. Conclusiones

Con un estado mínimo (tendencia discretizada y posición), Q-learning y Sarsa aprenden en cada mercado la estrategia que su generador hace razonable: seguir la tendencia cuando hay ciclo, operar a la contra cuando hay reversión y no operar cuando no hay información. Superan siempre al agente aleatorio y a buy & hold salvo en el browniano, donde lo empatan con mucho menos riesgo. Las diferencias entre algoritmos son de prudencia más que de rendimiento, y la principal limitación es la información que contiene el estado, no el algoritmo.