Agentes tabulares de aprendizaje por refuerzo para invertir en un activo: Q-learning y Sarsa

Aprendizaje por Refuerzo, MIAX-14 · Taller trader · Grupo: Alonso, Piettro y Raúl · Código y resultados: github.com/raulrodriguezlr/B5-Reinforcement-learning

1. Planteamiento y decisiones de diseño

- **Entorno.** Se usa `SimpleTradingEnv` del enunciado sin cambios: acciones vender, mantener y comprar; recompensa igual al retorno del paso si se tiene el activo, menos 0,1 % por operación; capital inicial 1000. Cada episodio recorre 494 pasos de una serie de 500 precios.
- **Estado discreto.** La tendencia observada es continua y, medida sobre series reales de cada generador, vive en torno a ±0,06 (±0,35 en tendencia + ciclo): el recorte a ±1 del entorno nunca actúa y diez tramos uniformes en [−1, 1] dejarían casi todos los estados en un único tramo. Por eso se discretiza en **10 tramos por cuantiles**, ajustados para cada generador con 200 series propias (nunca de test). El estado es (tramo, posición) y la tabla Q tiene forma 10×2×3.
- **Entrenamiento.** Cada episodio usa una **serie nueva** del mismo generador. Política ε-greedy con ε decreciente de 1 hasta un mínimo ε_{min} y α decreciente (×0,998 por episodio, mínimo 0,01): con α constante la política greedy seguía cambiando en casi todos los episodios por valores Q casi empatados.
- **Datos y ajuste.** Semillas disjuntas para entrenamiento, validación (50 series) y test (100 series). Hiperparámetros elegidos solo en validación (mediana del log-retorno de la política greedy) con la rejilla α ∈ {0,05; 0,2}, γ ∈ {0; 0,9; 0,99}, decaimiento de ε ∈ {0,995; 0,999} y 3 semillas. Gana γ = 0,9 en tendencia + ciclo y γ = 0,99 en reversión; en browniano y regímenes casi todo empata en "no operar". Después, en torno a ese óptimo (un factor cada vez), se barre **ε_{min} ∈ {0; 0,05; 0,2} y el número de episodios** (hasta 6000, validación cada 250, 5 semillas; como α y ε decaen por episodio, cada punto equivale a entrenar N episodios). Se elige el ε_{min} de mejor meseta (0,05 si empata) y el primer N que queda en tolerancia de ella.
- **Evaluación.** 5 semillas por algoritmo; política greedy final sobre las mismas 100 series de test que los baselines (aleatorio, buy & hold). Medianas por serie, porque el generador 1 da balances muy asimétricos. Convergencia, con dos criterios fijados una vez para todos: (val) primer episodio desde el que el rendimiento en validación queda en tolerancia del valor final durante al menos 200 episodios; (MA) primer episodio desde el que la media móvil de 100 episodios de la recompensa de entrenamiento queda a menos de 3 errores estándar de su valor final (tolerancia 0,3·std).

2. Resultados en test

Generador	Método	Episod. / ε_{min}	Balance	Log-ret. ± std	Exc. B&H (log)	Sharpe	DD (%)	Oper.	% merc.	Conv. val (ep.)	Conv. MA (ep.)	Conv. MA (s)
Tendencia + ciclo	**Q-learning**	**1250 / 0,05**	**512 096**	**6,32 ± 0,31**	**2,55**	**0,194**	**61,3**	**55**	**59,5**	**n/c (0/5)**	**950 (5/5)**	**19,9**
	Sarsa	**500 / 0,05**	**366 888**	**6,00 ± 0,23**	**2,30**	**0,193**	**61,0**	**60**	**54,7**	**n/c (0/5)**	**337 (5/5)**	**6,2**
	Buy & hold	n/c	33 458	3,61	0,00	0,120	89,2	1	100,0	n/c	n/c	n/c
	Aleatorio	n/c	4 568	1,60	−2,09	0,078	78,3	166	49,0	n/c	n/c	n/c
Browniano	**Q-learning**	**4500 / 0,05**	**1 000**	**0,00 ± 0,00**	**0,01**	**0,000**	**0,0**	**0**	**0,0**	**3974 (4/5)**	**589 (5/5)**	**11,4**
	Sarsa	**500 / 0**	**1 000**	**−0,02 ± 0,04**	**0,00**	**0,000**	**0,0**	**0**	**0,0**	**299 (1/5)**	**299 (5/5)**	**7,4**
	Buy & hold	n/c	989	−0,01	0,00	0,009	37,7	1	100,0	n/c	n/c	n/c
	Aleatorio	n/c	809	−0,17	−0,18	−0,024	32,2	166	49,0	n/c	n/c	n/c
Reversión a la media	**Q-learning**	**1500 / 0**	**1 289**	**0,25 ± 0,02**	**0,25**	**0,048**	**16,3**	**34**	**33,6**	**886 (4/5)**	**984 (5/5)**	**21,6**
	Sarsa	**5000 / 0**	**1 215**	**0,18 ± 0,04**	**0,19**	**0,045**	**14,3**	**42**	**20,5**	**4449 (5/5)**	**3658 (5/5)**	**85,3**
	Buy & hold	n/c	994	−0,00	0,00	0,010	25,5	1	100,0	n/c	n/c	n/c
	Aleatorio	n/c	872	−0,14	−0,15	−0,013	30,8	166	49,0	n/c	n/c	n/c
Regímenes	**Q-learning**	**6000 / 0**	**1 000**	**0,01 ± 0,03**	**0,16**	**0,000**	**0,0**	**0**	**0,0**	**5699 (2/5)**	**4044 (5/5)**	**86,3**
	Sarsa	**6000 / 0,05**	**1 000**	**0,00 ± 0,00**	**0,14**	**0,000**	**0,0**	**0**	**0,0**	**4516 (3/5)**	**530 (5/5)**	**12,1**
	Buy & hold	n/c	874	−0,16	0,00	−0,007	43,4	1	100,0	n/c	n/c	n/c
	Aleatorio	n/c	767	−0,26	−0,12	−0,033	35,1	166	49,0	n/c	n/c	n/c

Tabla 1. 100 series de test por generador (agentes: 5 semillas). Medianas por serie, salvo el log-retorno (media ± desviación entre semillas). Episod.: N elegido en validación. Exc. B&H: mediana por serie de la diferencia de log-retorno frente a buy & hold. Conv. val y Conv. MA: episodio medio de las semillas que convergen (convergidas/total) según validación greedy o media móvil de la recompensa de entrenamiento; n/c, sin convergencia en N episodios. Conv. MA (s): segundos de entrenamiento hasta ese episodio, con los cuatro generadores a la vez (unos 20 ms por episodio, el doble que en solitario).

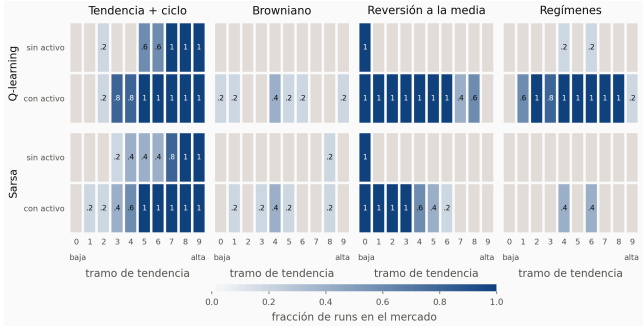


Figura 1. Política greedy final: fracción de las 5 semillas cuya acción deja la cartera dentro del mercado, por tramo de tendencia (0 la más baja) y posición actual. Gris: ninguna semilla entra.

3. Análisis por generador: ¿es la estrategia esperada?

- **Tendencia + ciclo: seguimiento de tendencia, esperado.** El agente entra con tendencia alta y sale con tendencia negativa (figuras 1 y 3). Multiplica el log-retorno de buy & hold (6,3 y 6,0 frente a 3,6) con menos drawdown (61 % frente a 89 %). El resultado es tan bueno porque el ciclo es determinista: `sin(t)` tiene la misma fase en todas las series (periodo de unos 63 pasos) y la tendencia de 6 pasos revela en qué tramo del ciclo se está. Es un patrón aprendible en este simulador, no una propiedad de un mercado real.
- **Browniano: no operar, esperado solo en mediana.** Con incrementos independientes la tendencia no informa del retorno siguiente y ninguna política bate en esperanza a buy & hold. La respuesta a la pregunta de clase depende del criterio: con μ = 0,0001 el retorno esperado por paso es positivo, así que para la recompensa del entorno (suma de retornos simples) lo óptimo es comprar y mantener (balance medio en test 1103 frente a 1000 sin operar); como $\mu < \sigma^2/2$, en mediana buy & hold pierde (log-retorno esperado −0,05) y no operar es mejor. El ajuste por mediana elige γ = 0, con el que comprar solo compensa si el retorno del paso siguiente supera la comisión, y ambos agentes se quedan en efectivo: empatan con buy & hold en mediana (exceso 0,01 y 0,00) con drawdown nulo.
- **Reversión a la media: estrategia contraria, esperada.** Compra solo en el tramo de tendencia más negativo y mantiene hasta que la tendencia se vuelve positiva. La asimetría entre entrar (solo en el tramo 0) y salir (Q-learning desde el tramo 7, Sarsa desde el 4) es una banda de histéresis que ahorra comisiones. Supera a buy & hold en 0,19 a 0,25 de log-retorno. Q-learning rinde más (log-retorno 0,25 frente a 0,18); Sarsa es más selectivo (21 % del tiempo en mercado frente a 34 %) con menor drawdown.
- **Regímenes: seguimiento de tendencia solo parcial.** Lo esperado es estar dentro en régimen alcista y fuera en bajista. En la serie mediana ninguno opera: Sarsa, ajustado con γ = 0, no compra nunca (Q de comprar negativa en todos los tramos); Q-learning, con γ = 0,99, entra solo en algunas semillas y, una vez dentro, mantiene casi siempre. Ambos superan a buy & hold (que pierde un 16 % en mediana porque el régimen bajista tiene más caída y volatilidad), pero sobre todo por evitar el mercado: una ventana de 6 pasos distingue mal el régimen oculto en un ruido del 1 al 2,5 % por paso.

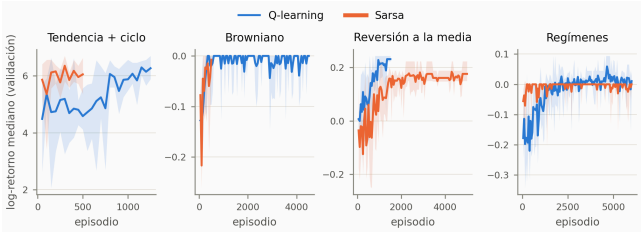


Figura 2. Mediana del log-retorno en validación de la política greedy durante el barrido de ε_{min} y N (cada 250 episodios; ε_{min} elegido): media de 5 semillas y banda entre mínimo y máximo.

4. Q-learning frente a Sarsa, ε_{min} y convergencia

El rendimiento es similar salvo en reversión, donde Q-learning rinde más. **La comparación no aísla el algoritmo**: cada uno tiene sus hiperparámetros. Sarsa no opera en regímenes por γ = 0 (Q-learning usa 0,99), no por ser *on-policy*; en reversión ambos acaban casi greedy (ε final 0,007 y 0,0005) y tienden a la misma política, así que la diferencia viene de α, del decaimiento de ε y de N. La prudencia de Sarsa del ejemplo del acantilado solo se espera con $\varepsilon_{min} > 0$. **ε_{min}:** con 0,2 la recompensa online empeora en los 8 casos y la política greedy nunca mejora en validación; 0 gana en reversión (ambos), en regímenes (Q-learning) y en browniano (Sarsa), y 0,05 en el resto. Explorar siempre no compensa en generadores estacionarios (en un mercado no estacionario podría hacerlo). **Número de episodios:** la meseta llega en 500 a 1500 episodios en tendencia + ciclo y en reversión (Q-learning); Sarsa en reversión necesita 5000 y en regímenes ambos llegan al tope de 6000; en browniano el N elegido sigue el ruido. **Convergencia:** la media móvil (Conv. MA) se cumple en las 40 ejecuciones, pero sigue sobre todo el calendario de ε, porque la recompensa de entrenamiento incluye el coste de explorar: 300 a 1000 episodios con decaimiento 0,995 y unos 3700 a 4000 con 0,999, sea cual sea el algoritmo (con N = 500 queda acotada por N). Para decir cuál converge antes habría que entrenar ambos con los mismos α, γ, ε y N. El criterio en validación greedy a menudo no se cumple porque la política oscila en celdas con valores Q casi empatados.



Figura 3. Una serie de test por generador: precio con sombreado donde Q-learning tiene el activo (arriba) y balance en escala logarítmica de cada método (abajo).

5. Extensiones

Generador	Q-learning	Sarsa	MC on-policy	MC off-policy	Q-learning mixto	Sarsa mixto	Buy & hold
Tendencia + ciclo	6,32 ± 0,31	6,00 ± 0,23	6,20 ± 0,33	2,77 ± 1,39	6,01 ± 0,23	6,00 ± 0,24	3,61
Browniano	0,00 ± 0,00	−0,02 ± 0,04	0,00 ± 0,00	−0,06 ± 0,09	−0,11 ± 0,05	−0,11 ± 0,03	−0,01
Reversión a la media	0,25 ± 0,02	0,18 ± 0,04	0,07 ± 0,07	−0,07 ± 0,17	−0,19 ± 0,06	−0,21 ± 0,09	−0,00
Regímenes	0,01 ± 0,03	0,00 ± 0,00	−0,03 ± 0,06	−0,19 ± 0,07	−0,18 ± 0,03	−0,18 ± 0,01	−0,16

Tabla 2. Log-retorno medio en test (± desviación entre semillas). MC reutiliza los hiperparámetros de Q-learning (6000 episodios); el mixto usa los valores por defecto (8000 episodios, un discretizador común). Ninguno tiene ajuste propio.

Generador	Método	5 tramos	10 tramos	20 tramos	comisión 0 %	comisión 0,1 %	comisión 0,5 %
Tendencia + ciclo	Q−learning	5,89 ± 0,59	6,32 ± 0,31	6,35 ± 0,17	6,46 ± 0,37 (45)	6,32 ± 0,31 (55)	6,20 ± 0,30 (43)
	Sarsa	5,82 ± 0,32	6,00 ± 0,23	6,27 ± 0,19	6,23 ± 0,25 (67)	6,00 ± 0,23 (60)	6,11 ± 0,33 (50)
Browniano	Q−learning	−0,03 ± 0,07	0,00 ± 0,00	−0,02 ± 0,03	0,00 ± 0,01 (0)	0,00 ± 0,00 (0)	0,00 ± 0,00 (0)
	Sarsa	−0,02 ± 0,05	−0,02 ± 0,04	−0,01 ± 0,03	0,00 ± 0,01 (0)	−0,02 ± 0,04 (0)	0,00 ± 0,00 (0)
Reversión a la media	Q−learning	0,15 ± 0,13	0,25 ± 0,02	0,22 ± 0,02	0,13 ± 0,07 (75)	0,25 ± 0,02 (34)	0,13 ± 0,07 (27)
	Sarsa	0,12 ± 0,10	0,18 ± 0,04	0,16 ± 0,03	0,18 ± 0,03 (52)	0,18 ± 0,04 (42)	0,02 ± 0,00 (1)
Regímenes	Q−learning	0,00 ± 0,00	0,01 ± 0,03	0,05 ± 0,02	0,03 ± 0,04 (0)	0,01 ± 0,03 (0)	0,00 ± 0,00 (0)
	Sarsa	0,00 ± 0,00	0,00 ± 0,00	0,00 ± 0,00	0,00 ± 0,00 (0)	0,00 ± 0,00 (0)	0,00 ± 0,00 (0)

Tabla 3. Log-retorno medio en test según tramos (comisión 0,1 %) y según comisión (10 tramos; entre paréntesis, operaciones por serie). Hiperparámetros ajustados para 10 tramos y 0,1 %.

- **Monte Carlo.** El on-policy (first-visit) iguala a Q-learning cuando la señal es grande (6,20 frente a 6,32 en tendencia + ciclo) pero rinde menos en reversión (0,07 frente a 0,25): usa retornos de episodio completo, de mucha varianza. El off-policy con importancia ponderada es el peor en los cuatro: en episodios de 494 pasos el peso se degrada y solo la cola de cada episodio actualiza Q.
- **Entrenamiento mixto.** Solo funciona en tendencia + ciclo (6,01). En los otros tres pierde (−0,11 a −0,21) y opera unas 90 veces: con el mismo estado, seguir la tendencia (tendencia + ciclo) y operar a la contra (reversión) piden acciones opuestas, y la observación no identifica el generador.
- **Número de tramos.** Con 5 el rendimiento baja y las semillas divergen más (reversión 0,15 ± 0,13); con 20 es similar a 10 dentro de la dispersión, así que 10 basta.
- **Comisión.** Con 0,5 % Sarsa deja de operar en reversión (0,02) y Q-learning recorta a 27 operaciones (0,13). Sin comisión no mejora: opera más (75) y rinde 0,13 frente a 0,25, así que la comisión del enunciado actúa también como regularizador (banda de histéresis).

6. Análisis crítico y limitaciones

- El estado (tendencia de 6 pasos, posición) no es markoviano: en regímenes el régimen está oculto y en reversión no se observa la distancia al equilibrio; ampliarlo (p. ej. desviación respecto a una media larga) es la mejora más directa.
- El generador 1 premia un ciclo de fase fija que no existe en series reales: los resultados no son trasladables a mercado (habría además sesgo de supervivencia y otros costes).
- El ajuste usa la meseta en validación con 3 semillas (rejilla) y 5 (barrido): es ruidoso y varía un factor cada vez. Además, recompensa y criterio no coinciden: el agente maximiza la suma de retornos simples (neutral al riesgo) y el ajuste premia la mediana del log-retorno, lo que favorece γ = 0 y no operar en browniano y regímenes.
- Pendiente: una serie real (con sesgo de supervivencia), normalizar la tendencia por volatilidad en el entrenamiento mixto y ajustar Monte Carlo y las variantes de comisión.

7. Conclusiones

Con un estado mínimo (tendencia discretizada y posición), Q-learning y Sarsa aprenden en cada mercado la estrategia que su generador hace razonable: seguir la tendencia cuando hay ciclo, operar a la contra cuando hay reversión y no operar cuando no hay información. Superan siempre al aleatorio, y a buy & hold en mediana salvo en el browniano, donde empatan con menos riesgo. Las diferencias entre algoritmos dependen tanto de los hiperparámetros como del algoritmo; la principal limitación es la información del estado.